

HISABU Nathan Tekeste

HILAIRE Kenny

SENTAYEHU Yeadonaye Ashenafi

MAGADIYEV Imam

BASSET Adrien

SAE S4.C.01 : Développement avec une base de données et visualisation

Partie 4 : Modèle IA de calcul du Nutri-Score



Table des matières

Table des matières.....	2
1. Introduction.....	3
2. Objectifs de la Partie 4	3
3. Outil choisie.....	3
4. Présentation du Workflow et de ses résultats.....	4
5.Conclusion	10

1. Introduction

Cette partie 4 porte sur la conception d'un modèle IA simple capable de calculer automatiquement un score nutritionnel équivalent au Nutri-Score, uniquement à partir des données disponibles dans Open Food Facts. Cette étape est la suite logique des parties précédentes, où nous avons d'abord nettoyé, analysé, visualisé les données et créer un agent IA capable d'aller interroger nos données pour y récupérer des informations. Comme nous avons pu le constater dans la partie 1, les données peuvent parfois être incomplètes ou incohérentes. Un modèle capable de détecter ces erreurs et de les corriger représenterait un outil essentiel pour améliorer la fiabilité des informations et faciliter leur interprétation, mais également pour permettre de combler l'absence de certaines informations en proposant des valeurs cohérentes.

2. Objectifs de la Partie 4

Conformément à ce qui est demandé, notre modèle doit être capable de :

- Détecter des erreurs ou incohérences dans les données saisies
- Calculer automatiquement un Nutri-Score
- Attribuer ce score à l'ensemble des produits du dataset
- Identifier les écarts entre le score calculé et le Nutri-Score existant.


Ce modèle doit rester simple et peu coûteux en ressources, et être exécutable sur un PC standard.

3. Outil choisie

Etant donnée que l'objectif est de créer un modèle certes efficace mais peu coûteux en ressource et simple, nous avons choisie d'utiliser KNIME (que nous avons déjà présenté et utilisé dans les parties précédentes) qui est outil d'analyse de données en "no code", permettant de construire des workflows sans avoir besoin de programmer, simplement en reliant des « nœuds » entre eux. Cela le rend particulièrement accessible et pratique pour manipuler des données, effectuer des transformations ou encore tester des modèles.



4. Présentation du Workflow et de ses résultats



Nœud 1 — CSV Reader

- Reçoit le fichier CSV Open Food Facts nettoyé


- C'est le point d'entrée du workflow
- Contient toutes les informations nutritionnelles des produits

Nœud 2 — Table Partitioner

- On sépare les données en deux parties : 80% train et 20 % test
- Permettra d'entraîner (train) notre modèle avant de l'évaluer(test)

Nœud 3 — Random Forest Learner

- Reçois 80% des données du Table Partitioner (6068 lignes)
- Entraîne le modèle de Machine-Learning
- Apprend à prédire la colonne nutrition_grade_fr à partir des colonnes définies



Nœud 4 — Random Forest Predictor (1 – celui du bas)

- Reçois 20% des données du Table Partitioner (1517 lignes)
- Applique le modèle (Random Forest Learner) sur des données qu'il ne connaît pas (les 20%)
- Crée une colonne contenant les prédictions de Nutri-Score

Prediction column name

Prediction (nutrition_grade_fr)

S nutrition_grade_fr	S Prediction (nutrition_grade_fr)
c	c
b	c
a	a
d	d
d	d
c	c
c	c
d	d
c	c
e	e
b	b
d	d
b	b
d	d
e	e
d	d
d	d
e	e
d	d
e	e
e	e
e	e
e	e
a	a
a	a
b	b
d	d
d	d
c	d
c	c
e	e
d	d
d	d
d	d
d	d
d	d

Résultat des prédictions du Nutri-score grâce au modèle sur 20 % de données qu'il ne connaît pas.

Nœud 5 — Scorer (1 – celui du bas)

- Évalue les performances du modèle
- Compare les prédictions avec les vraies valeurs via une matrice de confusion
- Donne des indicateurs de précision (Ex : 92% d'accuracy pour notre modèle)

Row ID	I TruePos...	I FalsePo...	I TrueNe...	I FalseNe...	D Recall	D Precision	D Sensitivity	D Specificity	D F-meas...	D Accuracy	D Cohen's...
b	201	24	1267	25	0.889	0.893	0.889	0.981	0.891	?	?
d	435	37	1019	26	0.944	0.922	0.944	0.965	0.932	?	?
c	264	38	1185	30	0.898	0.874	0.898	0.969	0.886	?	?
a	185	6	1314	12	0.939	0.969	0.939	0.995	0.954	?	?
e	315	12	1166	24	0.929	0.963	0.929	0.99	0.946	?	?
Overall	?	?	?	?	?	?	?	?	?	0.923	0.901

Row ID	I b	I d	I c	I a	I e
b	201	0	20	5	0
d	0	435	14	0	12
c	13	16	264	1	0
a	9	0	3	185	0
e	2	21	1	0	315

Nœud 6 — Rule Engine

- Définit une expression
- Crée une colonne de comparaison entre la prédiction et le Nutri-score réel
- Indique « OK » la prédiction est égale au vrai Nutri-score et « DIFF » sinon


Expression

S	1	\$nutrition_grade_fr\$ = \$Prediction (nutrition_grade_fr)\$ => "OK"
S	2	TRUE => "DIFF"

Column: S

Nœud 7 — Bar Chart (1)

- Visualise les résultats sous forme de graphique
- Permet de voir les écarts entre le score calculé et le Nutri-Score existant sur 20 % de données



Nœud 8 — GroupBy

- Regroupe les données par comparaison_nutri
- Permet de voir les écarts entre le score calculé et le Nutri-Score existant sur 20 % de données
- 1400 lignes = OK contre 117 lignes = DIFF

Settings: Description Flow Variables Job Manager Selection Memory Policy

Groups Manual Aggregation Pattern Based Aggregation Type Based Aggregation

Group settings

Available column(s)

Filter

product_name
brands_tags
categories_en

Group column(s)

Filter

comparaison_nutri

Settings: Description Flow Variables Job Manager Selection Memory Policy

Groups Manual Aggregation Pattern Based Aggregation Type Based Aggregation

Aggregation settings

Available columns

product_name
brands_tags
categories_en

Select

To change multiple columns use right mouse click for context menu.

Column	Aggregation (click to change)	Missing	Parameter
product_name	Count	☒	

Row ID	compar...	Count(p...
Row0	DIFF	117
Row1	OK	1400

Nœud 9 — Random Forest Predictor (2 – celui du haut)

- Applique le modèle sur la totalité des données
- Permet de généraliser les résultats
- Crée une colonne contenant les prédictions de Nutri-Score

nutrition_grade_fr	Prediction (nutrition_grade_fr)
c	c
b	c
a	a
d	d
d	d
c	c
c	c
d	d
c	c
e	e
b	b
d	d
b	b
d	d
e	e
d	d
d	d
e	e
d	d
e	e
e	e
e	e
e	e
a	a
a	a
b	b
d	d
d	d
c	d
c	c
e	e
d	d
d	d
d	d
d	d

Résultat des prédictions du Nutri-score grâce au modèle sur la totalité des données (dont les 80% sur lequel il s'est entraînés)

Nœud 10 — Scorer (2 – celui du haut)

- Évalue à nouveau les performances
- Vérifie la cohérence du modèle
- Donne des indicateurs de précision (Ici 98% d'accuracy pour notre modèle)

On obtient logiquement de meilleurs résultats car ici on a appliqué le modèle sur la totalité des données, étant donné qu'il s'est déjà entraîné sur 80 % des données il aura plus de facilité à déterminer le Nutri-score des données sur lequel il s'est entraîné.

Le passage de 92% à 98% d'accuracy montre donc que le modèle a très bien appris, mais que le score de 92% est le plus "honnête" car il représente la capacité du modèle à deviner des produits qu'il n'a jamais vus auparavant !

Accuracy statistics - 3:23 - Scorer

File Edit Hilite Navigation View

Table "default" - Rows: 6 Spec - Columns: 11 Properties Flow Variables

Row ID	TruePos...	FalsePo...	TrueNe...	FalseNe...	Recall	Precision	Sensitivity	Specificity	F-meas...	Accuracy	Cohen's...
b	1178	37	6344	26	0.978	0.97	0.978	0.994	0.974	?	?
d	2148	41	5368	28	0.987	0.981	0.987	0.992	0.984	?	?
c	1478	39	6027	41	0.973	0.974	0.973	0.994	0.974	?	?
a	1087	7	6479	12	0.989	0.994	0.989	0.999	0.991	?	?
e	1557	13	5985	30	0.981	0.992	0.981	0.998	0.986	?	?
Overall	?	?	?	?	?	?	?	?	?	0.982	0.977

Confusion matrix - 3:23 - Scorer


File Edit Hilite Navigation View

Table "spec_name" - Rows: 5 Spec - Columns: 5 Properties Flow Variables

Row ID	b	d	c	a	e
b	1178	0	20	6	0
d	0	2148	15	0	13
c	22	18	1478	1	0
a	9	0	3	1087	0
e	6	23	1	0	1557

Nœud 11 — Bar Chart (2)

- Visualise les nouveaux résultats sous forme de graphique
- Permet de voir les écarts entre le score calculé et le Nutri-Score existant sur la totalité des données



5.Conclusion

La réalisation de cette quatrième partie a permis de concrétiser l'objectif de fiabilisation des données Open Food Facts par l'intelligence artificielle. En utilisant l'outil KNIME, nous avons mis en place un modèle " efficace, répondant capable de calculer automatique le nutri-Scorer de chaque produit de façon simple

Points clés de la réalisation :

- **Performance du modèle** : L'utilisation du nœud Random Learner a permis une excellente précision, avec une accuracy de 92% sur le jeu de test (20% du dataset) et atteignant 98% sur l'ensemble du dataset.
- **Comparaison** : Le workflow ne se contente pas de prédire un score ; il identifie activement les incohérences. Sur notre échantillon de test, nous avons pu valider 1400 prédictions conformes ("OK") tout en isolant 117 écarts ("DIFF"), permettant ainsi de cibler les erreurs potentielles de saisie dans la base d'origine.
- **Analyse de données** : Grâce aux nœuds de visualisation (**Bar Charts**) et de regroupement (**GroupBy**), nous avons pu créer un Dashboard permettant de démontrer visuellement l'objet de notre analyse, en montrant les comparaisons entre les prédictions du modèle et le nutri-score réellement attribué dans la base de données de Open Food Facts.