

HISABU Nathan Tekeste
HILAIRE Kenny
SENTAYEHU Yeadonaye Ashenafi
MAGADIYEV Imam
BASSET Adrien

SAE S4.C.01 : Développement avec une base de données et visualisation



Table des matières

Table des matières.....	1
Analyse et préparation des données.....	2
Introduction.....	2
I) Exploration du dataset.....	2
II) Analyse de la qualité des données.....	2
III) Plan de nettoyage et sélection des variables.....	3
Les colonnes conservé pour cette analyse sont les suivantes :.....	4
IV) Traitement des données avec KNIME.....	5
V) Complétion des données par Similarity Search.....	6
Conclusion.....	7
Visualisation des données.....	8
Introduction.....	8
I) KPI et indicateurs définis.....	8
II) Analyses et visualisations réalisées.....	10
III) Nos Dashboards.....	16
IV) Méthodologie.....	17
V) Conclusion.....	18
Abstract.....	19

Analyse et préparation des données

Introduction

Les données Open Food Facts sont issues de contributions collaboratives. Elles sont donc très riches, mais présentent également plusieurs limites : certaines informations sont incomplètes, hétérogènes ou incohérentes.

Avant toute analyse ou exploitation, il est donc indispensable de comprendre la structure du dataset et d'évaluer la qualité des données.

L'objectif de cette première partie est donc de :

- analyser la structure du dataset (produits, variables, types),
- identifier les problèmes de qualité (valeurs manquantes, doublons),
- repérer les incohérences dans les données nutritionnelles,
- proposer un plan de nettoyage des données (avec KNIME ou un autre outil) qui servira de base aux analyses suivantes.

I) Exploration du dataset

Nous avons exploré le dataset **small_open_foodfacts.csv**, qui contient **10 003 lignes**, chacune représentant un produit alimentaire.

Le fichier comporte également un grand nombre de colonnes décrivant différentes caractéristiques des produits.

Ces colonnes sont de types variés :

- **Variables numériques** : valeurs nutritionnelles (sucre, sel, énergie, matières grasses), poids, portions ou certains minéraux.
- **Variables catégorielles** : Nutri-Score, catégories de produits, labels (bio, etc.), marques ou pays.
- **Variables textuelles** : nom du produit, liste d'ingrédients ou descriptions.

Certaines colonnes contiennent également des identifiants ou des métadonnées, comme les codes-barres, les URLs ou les informations sur le créateur de la fiche produit.

Cette première exploration nous a permis de mieux comprendre la structure générale du dataset avant de procéder à son analyse de qualité.

II) Analyse de la qualité des données

L'analyse du dataset a permis d'identifier plusieurs problèmes de qualité des données.

Tout d'abord, certaines colonnes présentaient un taux très élevé de valeurs manquantes (supérieur à 50 %), ce qui les rend difficilement exploitables pour l'analyse.

Nous avons également observé la présence de colonnes redondantes, par exemple :

- states
- states_tags
- states_en

Ces colonnes contiennent des informations similaires sous des formats différents. Nous avons donc choisi de conserver uniquement les colonnes se terminant par **_tags**, car elles sont généralement plus normalisées et plus faciles à exploiter pour l'analyse.

Enfin, certaines incohérences dans les valeurs nutritionnelles ont été identifiées. Par exemple, certains produits indiquaient des valeurs impossibles, comme **200 g de sucre pour 100 g de produit**.

De plus, certains produits présentaient des Nutri-Scores manquants ou incohérents par rapport aux nutriments renseignés.

Certaines catégories de produits étaient également absentes ou mal renseignées, ce qui peut compliquer les analyses statistiques.

III) Plan de nettoyage et sélection des variables

À partir de cette analyse, nous avons défini un plan de nettoyage des données afin de préparer le dataset pour les analyses futures.

La première étape a consisté à supprimer les colonnes non pertinentes pour notre projet, comme par exemple :

- les informations sur les vitamines,
- les URLs,
- les champs creator ou created,
- les codes d'emballage (emb_codes).

Nous avons ensuite supprimé :

- les colonnes contenant trop de valeurs manquantes,
- les colonnes redondantes,
- les colonnes contenant des données incohérentes ou peu exploitables.

À l'issue de ce processus, nous avons établi une liste de variables pertinentes à conserver pour la suite du projet.

Pour certaines colonnes conservées comportant encore quelques valeurs manquantes, nous avons choisi :

- soit de les conserver telles quelles,
- soit de les compléter lorsque cela était possible de manière logique.

Ce choix permet de conserver les données proches de leur source tout en assurant une meilleure fiabilité pour les analyses suivantes.

Cette sélection représente un compromis entre la richesse du dataset original (9 Go) et l'échantillon de travail utilisé (1 Go). En éliminant les colonnes trop incomplètes ou redondantes, nous limitons les risques de biais et facilitons l'exploitation des données dans la Partie 2 (analyses statistiques) et la Partie 3 (analyses IA).

Les colonnes conservé pour cette analyse sont les suivantes :

Nom_colonne	Pourquoi les conserver ?
product_name	Permet d'identifier clairement chaque produit et de faciliter la lecture des graphiques.
brands_tags	Permet d'analyser et de comparer les produits selon leur marque.
categories_en	Permet de classer les produits par catégories alimentaires.
countries_en	Permet d'identifier les pays de commercialisation des produits.
ingredients_text	Donne la liste des ingrédients composant le produit.
additives_en	Permet d'identifier les additifs présents dans les produits.
ingredients_from_palm_oil_n	Indique le nombre d'ingrédients contenant de l'huile de palme.
nutrition_grade_fr	Correspond au Nutri-Score, indicateur global de la qualité nutritionnelle.
states_en	Indique l'état de la fiche produit dans la base de données.
energy_100g	Indique la valeur énergétique pour 100 g de produit.

fat_100g	Indique la quantité totale de matières grasses.
saturated-fat_100g	Indique la quantité de graisses saturées.
carbohydrates_100g	Indique la quantité totale de glucides.
sugars_100g	Indique la quantité de sucres dans le produit.
fiber_100g	Indique la quantité de fibres alimentaires.
proteins_100g	Indique l'apport en protéines du produit.
salt_100g	Indique la quantité de sel dans le produit.
sodium_100g	Variable liée au sel, utile pour l'analyse nutritionnelle.
calcium_100g	Indique la teneur en calcium.
iron_100g	Indique la teneur en fer.
code	Code permettant d'identifier chaque produit.
nutrition-score-fr_100g	Score utilisé pour calculer le Nutri-Score.
Distributeur	Permet d'identifier le distributeur du produit.
Temps	Permet d'ajouter une dimension temporelle à l'analyse.

IV) Traitement des données avec KNIME


Afin de réaliser le nettoyage et la préparation des données, nous avons utilisé l'outil KNIME, qui permet de construire un workflow visuel de traitement de données.

Le workflow commence par l'importation du fichier **small_open_foodfacts.csv** à l'aide du nœud **CSV Reader**.

Une fois les données chargées, plusieurs opérations de préparation ont été appliquées :

- sélection des colonnes utiles à l'analyse,
- traitement des valeurs manquantes,
- suppression des colonnes trop incomplètes,
- vérification de la cohérence des données nutritionnelles,
- suppression des valeurs aberrantes.

Enfin, les données nettoyées ont été conservées sous forme d'un dataset final structuré, prêt à être utilisé pour les analyses statistiques et les visualisations dans la suite du projet.



V) Complétion des données par Similarity Search

Afin d'améliorer la qualité du dataset, nous avons mis en place une méthode de complétion des valeurs manquantes basée sur une recherche de similarité entre produits.

Cette approche a été utilisée principalement pour des colonnes importantes telles que **categories_en** et **labels_tags**, qui présentaient un grand nombre de valeurs manquantes.

Le principe repose sur la comparaison des noms de produits.

Dans un premier temps, nous avons utilisé le dataset complet d'Open Food Facts (environ 9 Go) comme base de référence. Chaque produit a été transformé en une représentation numérique appelée **empreinte (embedding)**, qui permet de capturer le sens et la similarité entre les noms de produits.

Ces empreintes ont ensuite été indexées à l'aide de la bibliothèque **FAISS**, un outil optimisé pour la recherche rapide de similarité.

Ensuite, pour chaque produit ayant une valeur manquante, nous avons recherché le produit le plus similaire.

- Si la similarité dépasse **55 %**, la valeur est complétée.
- Sinon, elle est laissée vide pour éviter les erreurs.

Exemple :

Un produit nommé "Peanuts" peut être rapproché de "Roasted Peanuts", dont la catégorie est "Snacks, Nuts".

Cette méthode a permis de réduire significativement le nombre de valeurs manquantes. Par exemple, la colonne **categories_en** est passée d'environ **7400 valeurs manquantes à seulement 11**.

Conclusion

Cette première étape d'analyse et de préparation des données a permis de mieux comprendre la structure du dataset Open Food Facts et d'identifier plusieurs problèmes de qualité, tels que les valeurs manquantes, les colonnes redondantes et certaines incohérences dans les données nutritionnelles.

Grâce à ce travail de nettoyage et de sélection des variables, nous avons pu construire un dataset plus fiable et plus exploitable pour les analyses futures.

Les colonnes conservées permettent à la fois d'identifier les produits, d'analyser leur composition nutritionnelle et de réaliser des comparaisons selon les marques, les catégories ou les pays.

Le traitement réalisé avec KNIME a permis de structurer efficacement les données et de préparer une base propre pour les analyses statistiques et les visualisations qui seront développées dans la Partie 2, ainsi que pour les analyses d'intelligence artificielle prévues dans la Partie 3.

Visualisation des données

Introduction

Cette partie vise à **transformer les données préparées en informations compréhensibles et utiles à la décision**, à l'aide d'analyses et de visualisations.

L'objectif n'est pas seulement de produire des graphiques, mais de **mettre en évidence des tendances, comparer des catégories de produits et identifier des points d'attention nutritionnels**.

Le travail attendu comprend :

- l'exploration des données à l'aide d'un workflow KNIME,
- la conception de **tableaux de bord interactifs** (Power BI ou équivalent),
- la proposition de plusieurs analyses pertinentes (**au moins 7**),
- la définition d'indicateurs clairs et exploitables (**KPI = Key Performance Indicator**).

Les visualisations doivent permettre de répondre à des **questions concrètes liées à la nutrition et à la qualité des produits**, couvrant :

- la dimension géographique,
- la qualité nutritionnelle,
- les catégories de produits,
- les marques,
- quelques enjeux de santé publique (sucre, bio, allergènes, ultra-transformés).

I) KPI et indicateurs définis

Pour cette analyse, nous avons choisi les KPI suivants : Ces indicateurs permettent d'évaluer la **qualité nutritionnelle**, la **répartition géographique** et les **habitudes de production** des produits alimentaires.

KPI	Description / Utilité
Nombre total de produits	Nombre total de produits dans le dataset.
Pourcentage de produits sains	% de produits avec un Nutri-Score A ou B.
Pourcentage de produits mauvais	% de produits avec un Nutri-Score D ou E.
Pourcentage de produits avec allergènes	% de produits contenant des allergènes.
Sucre moyen (g/100g)	Quantité moyenne de sucre par 100 g de produit.
Sel moyen (g/100g)	Quantité moyenne de sel par 100 g de produit.
Graisse moyenne (g/100g)	Quantité moyenne de matières grasses par 100 g de produit.
Pourcentage de produits bio	% de produits labellisés bio.


Pourcentage de produits à sel élevé	% de produits dépassant la limite recommandée en sel.
Nombre moyen de labels	Nombre moyen de labels présents par produit.
Nombre de pays distincts	Nombre de pays dans lesquels les produits sont commercialisés.
Nombre de marques distinctes	Nombre de marques différentes présentes dans le dataset.
Pourcentage de produits USA	% de produits produits ou commercialisés aux États-Unis.
Marque dominante	Marque ayant le plus grand nombre de produits dans le dataset.

II) Analyses et visualisations réalisées

Nous avons réalisé **12 visualisations** afin d'analyser les données et répondre à des problématiques concrètes liées à la nutrition, à la qualité des produits et à leur répartition.


1. Répartition des produits par Nutri-Score (A à E)

Ce graphique permet d'avoir une vision globale de la qualité nutritionnelle des produits. Il met en évidence la proportion de produits sains (A, B) par rapport aux produits moins favorables (D, E).




2. Sucre moyen vs limite OMS

Réalisé sous forme de jauge, ce graphique compare la quantité moyenne de sucre dans les produits à la recommandation de l'OMS (25 g/100 g). Il permet d'évaluer rapidement si le dataset présente un risque global lié au sucre.




3. Nutri-Score et nombre de produits par distributeur

Ce diagramme en barres permet de comparer les distributeurs selon le nombre de produits qu'ils proposent, tout en mettant en évidence leur répartition en termes de Nutri-Score. Il permet ainsi d'identifier quels distributeurs offrent le plus de produits et d'évaluer la qualité nutritionnelle globale de leur offre.




4. Sucre moyen par catégorie

Cette visualisation permet d'identifier les catégories les plus sucrées et donc celles qui peuvent représenter un risque nutritionnel plus élevé.




5. Corrélation sucres vs graisses par Nutri-Score

Le nuage de points montre la relation entre la quantité de sucre et de matières grasses. Il permet de visualiser que les produits les plus riches en ces nutriments sont généralement associés à de mauvais Nutri-Scores.




6. Pourcentage de produits bio par distributeur

Ce graphique compare les distributeurs selon la part de produits biologiques qu'ils proposent, ce qui permet d'évaluer leur positionnement en termes de qualité et d'alimentation durable.




7. Nombre moyen d'additifs par catégorie

Cette analyse met en évidence les catégories contenant le plus d'additifs, ce qui permet d'identifier les produits les plus transformés.




8. Volume des produits par catégorie (treemap)

Le treemap permet de visualiser la répartition globale des produits selon leur catégorie en fonction de leur volume, offrant une vue synthétique de l'importance de chaque catégorie.




9. Top 6 marques par nombre de produits

Ce graphique permet d'identifier les marques les plus présentes dans le dataset, et donc celles qui dominent en termes de volume de produits.




10. Répartition des produits par pays

Cette visualisation met en évidence les pays les plus représentés, permettant d'analyser la dimension géographique du dataset.




11. Nutri-Score moyen par marque (Top 6)

Ce graphique permet de comparer la qualité nutritionnelle moyenne des principales marques, et d'identifier celles qui proposent des produits plus équilibrés.






12. Nutri-Score moyen par pays

Cette analyse permet de comparer la qualité nutritionnelle des produits selon les pays, et de mettre en évidence d'éventuelles différences alimentaires ou industrielles.



III) Nos Dashboards





IV) Méthodologie

Pour réaliser ces visualisations :

1. Nous avons utilisé **KNIME** pour explorer et préparer les données nettoyées de la Partie 1.
2. Nous avons construit les indicateurs KPI à partir des colonnes sélectionnées.
3. Les visualisations ont été réalisées sur **Power BI**, permettant la création de **dashboards interactifs**.
4. Les graphiques sont liés aux indicateurs et permettent d'identifier rapidement :
 - les produits “exemplaires”,
 - les points d'attention nutritionnels (sucre, sel, additifs),
 - la répartition des produits selon marques, catégories et pays.

V) Conclusion

Cette partie a permis de :

- **Transformer les données brutes en informations exploitables**,
- Identifier les tendances par pays, marques, catégories et distributeurs,
- Mettre en évidence les points critiques liés à la nutrition (sucre, sel, additifs),
- Fournir une base pour la **prise de décision** et pour des analyses plus approfondies en santé publique.

Les dashboards interactifs réalisés sur Power BI offrent une **lecture intuitive et rapide**, permettant de comparer facilement les produits selon plusieurs dimensions (géographique, nutritionnelle, catégorielle).

Abstract

Open Food Facts is an open-source database that provides detailed information about food products from around the world, including nutritional values, ingredients, additives, categories, and labels. In this project, we worked with a dataset called *small_open_foodfacts.csv*, which contains 10,003 products, each representing a different food item. Because the database is collaborative, it is very rich in information, but it also contains challenges such as missing values, inconsistencies, and redundant or incomplete data.

The goal of this project is to analyze, clean, and visualize this dataset in order to better understand the nutritional quality, categorization, and distribution of food products. The project is divided into four main parts.

In the first part, we explored the dataset, identified data quality issues, and designed a cleaning process using KNIME. This included selecting relevant variables, handling missing data, and correcting inconsistent nutritional values. We also applied a similarity-based method to fill in missing information in important columns, which improved the overall quality of the dataset.

The second part focuses on data visualization. Using the cleaned data, we defined Key Performance Indicators (KPIs) to evaluate product quality, nutritional content, and distribution across countries, brands, and categories. We then created interactive dashboards in Power BI to highlight trends, compare products, and identify key issues such as high sugar content, bio labeling, and the presence of additives.

The third part involves deeper statistical analysis to better understand nutritional trends and relationships between variables, such as categories, health indicators, and geographical differences. Finally, the fourth part explores the use of machine learning techniques to predict nutritional scores or classify products based on their characteristics.

Overall, this project shows how data cleaning, analysis, and visualization can transform a complex dataset into clear and useful insights, helping to better understand food products and their impact on nutrition and public health.